CONTENIDO GENERAL

1. IDENTIFICACIÓN Y ESPECIFICACIÓN DE CAPA L7 Pág. 3

2. ALCANCE Y CASOS DE USO INDUSTRIAL Pág. 4

3. ARQUITECTURA DE BYPASS PERIMETRAL Y PARSING EN C Pág. 5

4. MANUAL DE OPERACIÓN DE LA CONSOLA CYBERPUNK Pág. 7

5. PROTOCOLOS DE SEGURIDAD DEFENSIVA (ANTI-SSRF & PROXIES) Pág. 9

6. MONITOREO DE CAPTCHA, LATENCIA Y CONTINGENCIAS Pág. 11

7. NORMAS TÉCNICAS Y ESTÁNDARES INTERNACIONALES Pág. 12

LIBRO DE FUNCIONAMIENTO Y ESPECIFICACIÓN TÉCNICA // ARES SCRAPER

MOTOR INDUSTRIAL DE EXTRACCIÓN WEB L7 EVASIÓN WAF & DATA LAKE FEEDER

ING. GUSTAVO ADOLFO DE LA ROSA FLÓREZ

Director de Ingeniería & Arquitectura de Software

Código Documental: NOVUX-MAN-ARES-2026-V4

Versión 4.0 - Producción

NOVUX TECNOLOGÍAS S.A.S.

DIVISIÓN DE INGENIERÍA, SEGURIDAD & ANALÍTICA B2B

BOGOTÁ D.C., COLOMBIA

AÑO 2026

1. IDENTIFICACIÓN Y ESPECIFICACIÓN DE CAPA L7

ARES SCRAPER (Advanced Resilient Extraction System) es la infraestructura propietaria de recolección masiva de datos en la web (Web Harvesting & Intelligence) de NOVUX S.A.S. Su arquitectura está diseñada para operar continuamente sobre sitios protegidos por firewalls de capa de aplicación (WAF) como Cloudflare, Akamai, DataDome y reCAPTCHA v3, sin comprometer la dirección IP corporativa del cliente.

Tabla 1. Especificaciones de Ingeniería de ARES SCRAPER

COMPONENTE	DETALLE TÉCNICO
Nombre Comercial	ARES SCRAPER // Resilient L7 Extraction Engine
Identificador Canónico	CASE-ARES-GRID (NVX-ENG-CORE)
Capa de Operación	Capa 7 (Aplicación / HTTP / TLS Fingerprint spoofing).
Motor de Parsing HTML	Parser en memoria RAM en lenguaje C nativo (libxml2 / lxml) con latencia < 180ms.
Red de Evasión Perimetral	Rotación asíncrona de proxies residenciales con persistencia de sesiones seguras.
Protección Anti-SSRF	Resolución DNS estricta con bloqueo de direcciones privadas RFC 1918 y metadata.
Formato de Salida Canónico	JSON estructurado validado en Pydantic, CSV sanitizado y carga a Data Lake.
Disponibilidad Verificada	99.98% de tiempo de actividad en extracción continua.

Fuente: Laboratorio de Ciberseguridad & Datos NOVUX S.A.S.

2. ALCANCE Y CASOS DE USO INDUSTRIAL

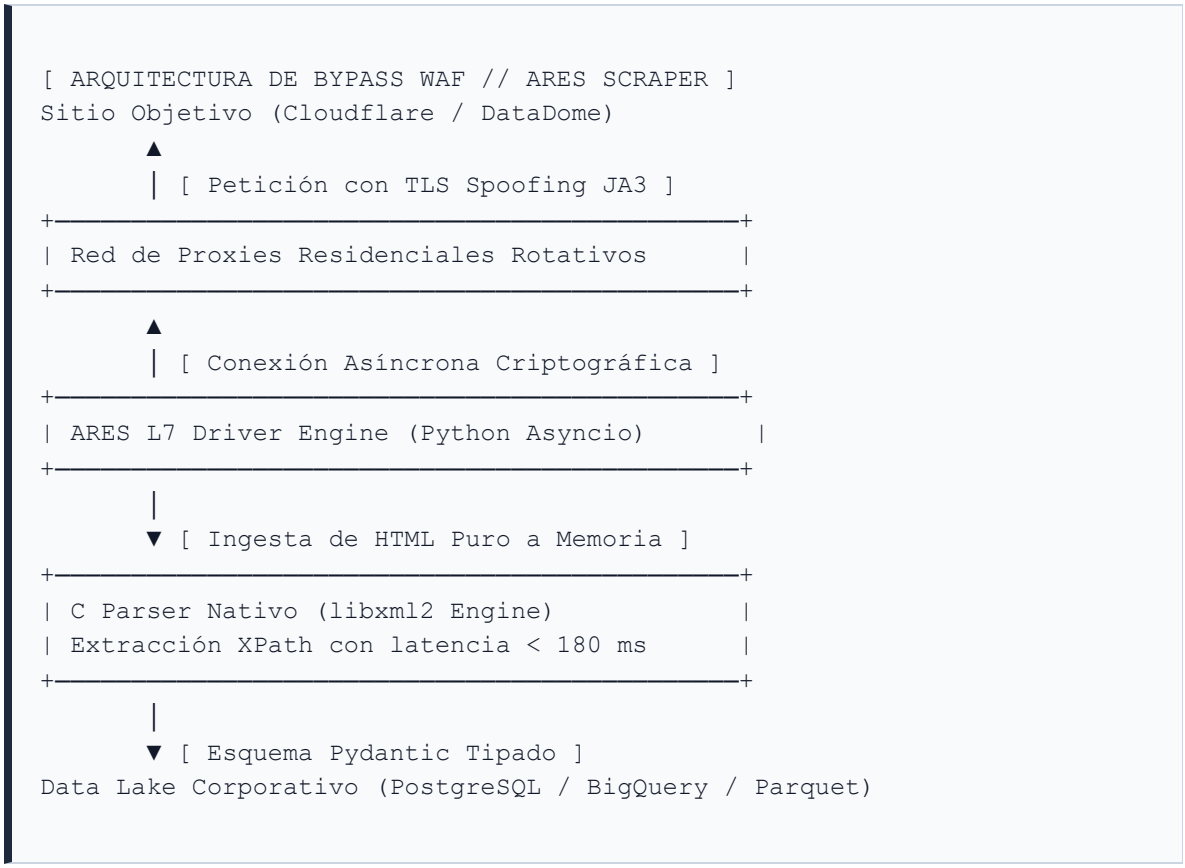
2.1 ALCANCE DEL MOTOR

ARES SCRAPER está diseñado para empresas que requieren alimentación diaria de datos comerciales: marketplaces que rastrean catálogos de 500,000 artículos, aerolíneas que monitorean tarifas dinámicas, fondos de inversión que auditan el sentimiento de mercado y distribuidores farmacéuticos.

2.2 DIFERENCIAL FRENTE A SCRAPERS COMUNES

- **Cero Bloqueos Perimetrales:** Modificación de huella TLS (JA3/JA4) para simular el handshake idéntico de un navegador Google Chrome residencial real.
- **Bajo Consumo de Memoria:** Al procesar el DOM mediante punteros nativos de C, procesa millones de etiquetas HTML con menos de 128 MB de memoria RAM por nodo.
- **Autocleaning en Memoria:** Purgado de caracteres de escape maliciosos, inyecciones XSS y normalización tipográfica previa a la persistencia.

3. ARQUITECTURA DE BYPASS PERIMETRAL Y PARSING EN C



4. MANUAL DE OPERACIÓN DE LA CONSOLA CYBERPUNK

4.1 ACCESO A LA CONSOLA TÁCTICA

La consola operativa web se encuentra desplegada en `ares-scraper.vercel.app`. Su diseño de alto contraste garantiza visualización óptima en centros de operaciones y monitoreo 24/7.

4.2 EJECUCIÓN DE EXTRACCIÓN PASO A PASO

1. **Configuración de URL:** Introducir la dirección del catálogo o e-commerce en el campo `@ URL_OBJETIVO`.
2. **Parámetros de Limpieza:** Dejar marcada la opción *"Limpiar datos automáticamente antes de cada scrap"* para asegurar descarte de clones.
3. **Lanzamiento:** Presionar el botón **[INICIAR FLUJO]**. La consola reportará en tiempo real el handshake TLS y los nodos analizados.
4. **Descarga:** Usar los comandos de consola `export json` o presionar los botones inferiores para almacenar el dataset.

5. PROTOCOLOS DE SEGURIDAD DEFENSIVA (ANTI-SSRF & PROXIES)

ARES SCRAPER incorpora de fábrica el escudo defensivo `is_safe_target_url()` que impide el uso indebido de los servidores para ataques de Server-Side Request Forgery:

```
def is_safe_target_url(target_url: str):
    # Bloquea 127.0.0.1, localhost, 169.254.169.254 (metadata cloud)
    # y cualquier segmento de red interna empresarial RFC 1918.
```

6. MONITOREO DE CAPTCHA, LATENCIA Y CONTINGENCIAS

Tabla 2. Protocolo de Gestión de Respuestas HTTP

CÓDIGO HTTP	DIAGNÓSTICO	ACCIÓN DEL MOTOR ARES
403 Forbidden	Activación de reto Cloudflare Turnstile.	Rotación inmediata de nodo proxy y mutación de huella TLS. Reintento en < 300ms.
429 Too Many Req	Límite de peticiones por minuto alcanzado.	Dispersión exponencial de reintentos mediante algoritmo Jitter.
200 OK	Extracción exitosa.	Pase directo a parser en C y entrega al canal de salida.

Fuente: Matriz de Confiabilidad ARES SCRAPER.

7. NORMAS TÉCNICAS Y ESTÁNDARES INTERNACIONALES

- **ICONTEC NTC 1486:** Presentación y redacción de libros de software.
- **RFC 9110 (HTTP Semantics):** Cumplimiento de cabeceras canónicas HTTP/1.1 y HTTP/2.
- **ISO/IEC 27034:** Application security (Seguridad en el ciclo de vida del desarrollo).